

大模型工具链与智能体技术笔记

LLM & Token | Prompt & MCP | RAG | Agent | Skills & Hooks & Plugin

01 核心引擎与数据单元 (LLM & Token)

Token 与 Tokenizer

Token 是大模型处理文本的最小单元。

1 Token $\approx$ 0.75 英文单词 $\approx$ 1.5 ~ 2 个汉字

Tokenizer 的两个核心功能：

- 编码 (Encode): 文字变数字
- 解码 (Decode): 数字变文字

Context Window 与 RAG 技术

上下文窗口 (Context Window)：代表模型能容纳的最大 Token 数量。例如 GPT-5.4 为 105 万，Claude Opus 为 100 万。

痛点：

当塞入模型的文档太大，成本极高且可能撑爆窗口。

解决方案：RAG (检索增强生成)

从手册中提取最匹配的片段 → 发送给模型 → 突破窗口限制，降低成本。

Tool 的功能

Tool 的功能：让大模型能够感知外部环境。

影响：工具赋予了大模型与外部世界交互的能力，超越了静态知识的局限。

02 Prompt (提示词)

Prompt：大模型接收的具体问题或指令。

Prompt Engineering (提示词工程)

核心原理：把话说清楚。

两种提示词：

类型	说明
System Prompt (系统提示词)	设定模型人设与规则，由开发者在后端隐式配置
User Prompt (用户提示词)	提出具体任务需求，由用户在对话框前端输入

MCP (模型上下文协议)

MCP：统一的接入协议，类似 Type-C 接口。

MCP 能够让大模型更好地使用各类工具。它是一个协议，定义了模型与外部工具之间的通信标准。

MCP 组成部分：

- MCP Host：支持 MCP 协议的软件（如 VS Code 里的 Claude 插件）
- MCP Server 和 Tool：MCP 服务器通常通过 Node 或 Python 本地启动

示例：OpenWeather Map (MCP Server)

- `get_forecast` → 获取天气预报
- `get_alerts` → 天气预警

安装 MCP Server：

1. 让 MCP Host 自动安装
2. 手动安装，在 json 中填入对应的启动命令

创建 MCP Server：

```
uv init weather    # 创建 weather 文件夹
cd weather
uv venv            # 创建虚拟环境
.venv/bin/activate  # 进入虚拟环境
uv add "mcp[cli]" httpx # 安装开发 MCP 必备的核心依赖
```

注意：MCP 协议未规定如何发现和调用函数，也没有规定如何与模型进行交互。

走向自主规划：Agent（智能体）

Agent 的思考与执行循环：

思考 (Think) → 规划 (Plan) → 执行/调用工具 (Act) → 观察 (Observe) → 循环

AI 底层框架全景图

从底层到顶层，AI 框架分为五个层次：

第一层：Structural（结构层）

LLM & Token —— 核心引擎，处理数据的最基本单元。

第二层：Container（容器层）

Context Window（记忆加工），包含 Prompt（意图控制）和 RAG（外挂知识库）。

第三层：Bridge（桥梁层）

MCP（能力拓展），连接工具与智能体的桥梁。

第四层：Orchestration（编排层）

Agent（自主大脑），负责规划和编排任务执行。

第五层：Agent Skill（定制行为指南）

专属的“行为说明书”，给 Agent 看的说明文档。

03 Agent Skills

Skills 类比炒菜

炒 菜 元 素	Skill 对应
流程	skill.md
配方	references
工具	scripts
材料	assets

创建 Skill (易→难)

示例：轻食店老板创建创意生成器 Skill

要求：

- 标准：品牌调性、视觉规范
- 输出：物料创意方案

Claude Skills 规定

目录结构：{project}/.claude/skills/{skill-name}/SKILL.md

渐进式披露机制：按需加载（三层结构）

1. 元信息（始终加载）
2. 指令层（按需加载）
3. 资源层（按需加载）

04 RAG（检索增强生成）

RAG 会将文档切分成多个分段，当用户提出一个问题后，根据这个问题在所有片段中寻找相关内容，把相关内容发给大模型。

整体流程：

提问前：分片 → 索引

提问后：召回 → 重排 → 生成

1. 分片（分成多个片段）

分片方式：

- (1) 按字数分
- (2) 按段落分
- (3) 按章节分

(4) 按页面分

2. 索引

可以根据 Embedding 转换为向量，查找文本相似度。

1. 通过 Embedding 将片段文本转换为向量
2. 将片段文本和片段向量存入向量数据库中

关键定义：

- 向量：有大小有方向的量
- Embedding：把文本转换为向量的过程，使用的是 Embedding 模型
- 向量数据库：用于存储和查询向量的数据库

3. 召回

搜索与用户问题最相关的片段。

流程：用户提问 → Embedding 模型 → 向量 → 向量数据库 → 返回 10 个最相似的结果（也可以是 5、20 等） → 搜索结果

向量相似度的计算方法：

方法	说明
余弦相似度	算两个向量之间夹角的 $\cos$ 值，夹角越小相似度越高
欧氏距离	算两个向量的距离，距离越小→相似度越高
点积	点积越大相似度越高；方向相反点积为负，方向垂直点积为 0

4. 重排

重新排序：从召回的结果中再挑出与用户问题最相似的片段。

召回（类似简历筛选）	重排（类似面试）
方法：向量相似度	方法：Cross-Encoder
成本低、耗时长、准确率低	成本高、耗时长、准确率高
适合场景：初步筛选	适合场景：精挑细选

5. 生成

用户问题 + 问题相关片段 → 大模型 → 用户

05 Agent（智能体）

LLM、Workflow 和 Agent 的区别

1. LLM

输入 → LLM → 输出。例如：“给我一份会议纪要模板”

2. Workflow（工作流）

执行人员规定好的步骤。例如：“上次会议是什么时候” → 日历 APP。

3. Agent

输入 → Agent 自己决定执行的步骤 → 输出。自己决定执行什么步骤。

示例：“帮我把上一次会议纪要总结一下，发到我的邮箱”

Workflow：输入→获取会议记录→调用 LLM 做摘要→接入邮箱→发邮件

Agent：①上一次会议时间？②尝试连接日历 ③试试用腾讯会议 ④调用大模型总结 ⑤不知道邮箱 ⑥问一下

Agent 的构成

类比招聘实习生，Agent 由以下部分组成：

- Prompt（岗位说明书）：职责、限制、回复风格
- LLM（大脑）：核心推理引擎
- Memory（记忆）：存储对话历史和上下文
- Tools（工具）：代替你操作电脑各个软件的权限
- External Knowledge（外部知识）：公司文档等

Agent Loop（智能体循环）

ReAct: Reasoning + Acting（推理 + 行动）

本质：思考 → 行动 → 检查

示例：问“帮我做竞品分析”

打开网页 → 搜索 → 整理文档 → 做图 → 检索结果 → 输出

06 Hooks（钩子）

在程序运行到某个关键节点时，提前留一个“挂接口”，让你可以插入自己的逻辑。Agent 的监督员，在关键节点强制检查。

Hook	触发时机
stop	主智能体结束前
SubagentStop	子智能体结束前
PreToolUse	调用工具前
PostToolUse	调用工具成功后
PostToolUseFailure	调用工具失败后
PreCompact / PostCompact	上下文压缩前/后
PermissionRequest	请求权限前

07 SubAgent（子智能体）

- (1) SubAgent 也是 Agent
- (2) 主 Agent 派出去的一个专门助手
- (3) 独立的上下文和工具权限
- (4) 主 Agent 可以把一个子任务交给它，让它在独立的上下文里完成，然后只把结果汇报回来，过程不污染主 Agent 的上下文
- (5) 可以多 Agent 并行处理任务

08 Plugin（插件）

核心公式：Skills + Hooks + MCP Server ⇒ Plugin

Claude Code 官方插件 (claude-plugins-official) :

1. skill-creator: 创建评估技能
2. claude-md-management: 根据历史对话, 优化 claude.md
3. code-simplifier: 简化并优化代码 (结合 claude.md 中自己定义的代码规范, 提升清晰度, 去掉冗余, 合并重复)
4. feature-dev: 全面、结构化的功能开发工作流, 配备专门的代理进行代码库探索、架构设计、质量审核
5. frontend-design: 前端优化避免 AI 味

09 Claude Code 核心功能概览

1. Skills (技能)
2. Plugin (插件)
3. Subagent (子智能体)
4. 自动化
5. CLAUDE.md: 初始化生成这个文件